

MI-SPOL-5

Matematika neurčitosti: vzdálenosti a další míry podobnosti, fuzzy množiny a operace s nimi, t-normy a t-konormy, entropie a její souvislost s neurčitostí.

Vzdálenost souvisí s podobností: vzdálenost roste, podobnost klesá

Vzdálenost založená na normě vektoru: $d(x, y) = \|y - x\|$

- $\|x\| \geq 0$
- $\|x\| = 0 \Leftrightarrow x = 0$
- $\|\alpha x\| = |\alpha| \cdot \|x\|$
- $\|x + y\| \leq \|x\| + \|y\|$

Druhy:

- obecná (Minkovského): $\|x\|_p = \sqrt[p]{\sum_{i=1}^n |x_i|^p}$, kde $p \in [1, \infty]$
- eukleidovská: $\|x\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2} = \sqrt{x^T x}$
- manhattanská: $\|x\|_1 = \sum_{i=1}^n |x_i|$
- čebyševská: $\|x\|_\infty = \max_{i=1, \dots, n} |x_i|$

Mahalanobisova vzdálenost: vzdálenost realizací x, y náhodných vektorů X, Y splňujících $EX = EY = \mu$, $\text{var} X = \text{var} Y = \Sigma$ pozitivně definitní

Jde o eukleidovskou vzdálenost $\sqrt{\Sigma^{-1}}(x - \mu)$ od $\sqrt{\Sigma^{-1}}(y - \mu)$.

$$\|\sqrt{\Sigma^{-1}}(x - \mu) - \sqrt{\Sigma^{-1}}(y - \mu)\| = \sqrt{(x - y)^T \Sigma^{-1} (x - y)}$$

Další míry podobnosti:

Podobnost náhodných veličin podle korelačních koeficientů:

- Pearsonův: $\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var} X \text{var} Y}}$
- Spearmanův: $\rho_{X, Y} = 12E(H(X, Y) - F(X)G(Y))$
- Kendalův: $\tau_{X, Y} = P[(X_1 - X_2)(Y_1 - Y_2) > 0] - P[(X_1 - X_2)(Y_1 - Y_2) < 0]$

Podobnost binárních vektorů: Hammingova vzdálenost (počet lišících se bitů)

Fuzzy množiny

Fuzzy množina: $A = (U, \mu_A)$, kde A je množina a $\mu_A : U \rightarrow [0, 1]$ je funkce příslušnosti prvků univerza U k množině A


Stupeň příslušnosti x k A : $\mu_A(x)$

$\mu_A(x) > 0$: nosič A


$\mu_A(x) = 1$: jádro A

Operace s fuzzy množinami


- $A \cap B : \mu_{A \cap B}(x) = \mu_A(x) \top \mu_B(x)$, kde $\top : [0, 1]^2 \rightarrow [0, 1]$ je **t-norma**



- $A \cup B : \mu_{A \cup B}(x) = \mu_A(x) \perp \mu_B(x)$, kde $\perp : [0, 1]^2 \rightarrow [0, 1]$ je **t-konorma**



- $A^c = U \setminus A : \mu_{A^c}(x) = 1 - \mu_A(x)$



T-normy

Vlastnosti:

- $u \top 0 = 0 \top v = 0$
- $u \top 1 = u$
- $1 \top v = v$
- Rostoucí v u, v
- $u > 0, v < 1 \Rightarrow 0 \leq u \top v \leq \min(u, v)$
- komutativní
- asociativní

Příklady:

- minimová (Gödelova): $u \top v = \min(u, v)$
- součinnová: $u \top v = uv$
- Łukasiewiczova: $u \top v = \max(0, u + v - 1)$
- Hamacherova rodina: $H_p(u, v) = \frac{uv}{p + (1-p)(u+v-uv)}, p \geq 0$

T-konormy

Vlastnosti:

- $u \perp 1 = 1 \perp v = 1$
- $u \perp 0 = u$
- $0 \perp v = v$
- Rostoucí v u, v
- $u > 0, v < 1 \Rightarrow \max(u, v) \leq u \perp v \leq 1$
- komutativní
- asociativní

Příklady:

- maximová: $1 - \max(u, v) = \min(1 - u, 1 - v)$

Duální pár:

- $1 - u \top v = (1 - u) \perp (1 - v)$
 - $1 - u \perp v = (1 - u) \top (1 - v)$
- (de Morganovy zákony)

Kopule: $C : [0, 1]^2 \rightarrow [0, 1]$ s vlastnostmi:

- $C(x, 0) = C(0, y) = 0$
- $C(x, 1) = x$
- $C(1, y) = y$
- $C(x_2, y_2) - C(x_2, y_1) - C(x_1, y_2) + C(x_1, y_1) \geq 0$

Kopule je někdy t-norma, vždy při $C(x, y) = f(f^{-1}(x) + f^{-1}(y))$, kde f je klesající konvexní

Sklarova věta: H je rozložení $(X, Y) \Leftrightarrow$ existuje kopule C splňující $H(X, Y) = C(F(X), G(Y))$ s pravděpodobností 1

Fuzzy zobrazení U do \hat{U} pro $A = (U, \mu_A)$:

Zobrazení $u \rightarrow F_A(u) = (\hat{U}, \mu_{F_A(u)})$

Mamdaniho metoda konstrukce $F_A(u)$: na základě pravidel

if(U, μ_{A_1}) then (\hat{U}, μ_{B_1}) ..., if(U, μ_{A_p}) then (\hat{U}, μ_{B_p})

$F_A(u) = \bigcup_{i=1}^p (B_i \cap \mu_{A_i}(u))$ při Gödelových \top, \perp

$\mu_{F_A(u)}(\hat{u}) = \max(\min(\mu_{B_1}(\hat{\mu}), \mu_{A_1}(\hat{\mu})), \dots, \min(\mu_{B_p}(\hat{\mu}), \mu_{A_p}(\hat{\mu})))$

Defuzzifikace: zobrazení fuzzy množiny do jejího univerza: $(U, \mu_A) \rightarrow U$

- Maximum μ_A

- Metoda těžiště: $u_{CG} = \frac{\int_S u \mu_A(u) du}{\int_S \mu_A(u) du}$

Fuzzy integrály: kombinace hodnot integrované funkce T-normami a T-konormami

- **Sugenův integrál:**

$$\int_U^{(S)} f dm = \max_i \min(f(x_{(i)}), m(A_{(i)})),$$

Alternativní zápis: $\perp_i (f(x_{(i)}) \top m(A_{(i)}))$

kde $A_i = \{x_{(1)}, \dots, x_{(k)}\}$, m je fuzzy míra

$(m(U) = 1, A \subset B \Rightarrow m(A) < m(B))$

- **Choquetův integrál:**

$$\int_U^{(C)} f dm = \sum_{i=1}^k f(x_{(i)}) (m(A_i) - m(A_{i-1}))$$

Entropie

Entropie diskrétní náhodné veličiny X : střední hodnota délky zápisu $P(x) = P(X = x)$ abecedou délky b

$$\mathcal{E}(X) = \sum_{x \in \mathcal{X}} P(x) \log_{\frac{1}{b}} P(x) = - \sum_{x \in \mathcal{X}} P(x) \log_b P(x)$$

Entropie spojité náhodné veličiny X :

$$\mathcal{E}(X) = - \int f(x) \log_b f(x)$$

, kde f je hustota X

Platí $0 \leq \mathcal{E} \leq \log_b n$

Minimální entropie: $\mathcal{E} = 0 \Leftrightarrow P(x_i) = 1$ pro nějaké x_i .

Žádná nejistota

Maximální entropie: $\mathcal{E} = \log_b n \Leftrightarrow P(x_1) = \dots = P(x_n) = 1/n$.

Největší nejistota

Relativní entropie kódování při rozdělení $(Q(x))_{x \in \mathcal{X}}$ vůči $(P(x))_{x \in \mathcal{X}}$

$$D(P||Q) = - \sum_{x \in \mathcal{X}} P(x) \log_b Q(x) - \mathcal{E}(X) = \sum P(x) \log_b \frac{P(x)}{Q(x)}$$

Vzájemná informace X a Y :

$$I(X, Y) = D(P_{(X,Y)} || P_X P_Y) = \sum P(X = x, Y = y) \log_b \frac{P(X = x, Y = y)}{P(x)P(y)} = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} P(x, y) \log_b \frac{P(x, y)}{P(x)P(y)}$$